

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ
ВЫСШЕГО ОБРАЗОВАНИЯ
«МОСКОВСКИЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ
ИМЕНИ Н.Э. БАУМАНА
(НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ)»
(МГТУ ИМ. Н.Э. БАУМАНА)

ФАКУЛЬТЕТ

ИУ «Информатика и системы управления»

КАФЕДРА

ИУ-1 «Системы автоматического управления»

ОТЧЁТ
ЛАБОРАТОРНАЯ РАБОТА №2

ДИСЦИПЛИНА: «Эргатические системы»

Студент

БОТВИНОВ К.И.

Студент

МОГИЛЬНИКОВА Т.А.

Группа

ИУ1-41М

Преподаватель

Д.А. АНДРИКОВ
(н.о., фамилия)

19/03/2025
(Подпись, дата)

Оценка

2025 г.

Введение

В данной работе производится классификация временного ряда ЭЭГ для определения эпилепсии. На основе изображений, представляющих вейвлет-преобразование ЭЭГ-сигнала, формируется датасет. С помощью сверточной нейронной сети из данных изображений выделяются полезные признаки, которые затем используются для анализа временного ряда с помощью LSTM-сети.

Описание датасета

Для исследования использовался датасет CHB-MIT Scalp EEG Database, содержащий записи электроэнцефалографии (ЭЭГ) детей с эпилепсией. Датасет включает 983 записи от 23 пациентов (возраст: 1.5–22 года), выполненные с использованием 23 каналов в формате EDF. Каждая запись длительностью около 1–4 часов содержит сигналы ЭЭГ с частотой дискретизации 256 Гц, а также аннотации начала и окончания эпилептических приступов (Seizure). Для анализа были выделены фрагменты сигналов, соответствующие классам "Healthy" (без приступов) и "Seizure" (с приступами). Сигналы фильтровались по частотным диапазонам (Delta: 0.5–4 Гц, Theta: 4–8 Гц, Alpha: 8–13 Гц, Beta: 13–30 Гц, Gamma: 30–100 Гц) и преобразовывались в вейвлет-изображения с помощью непрерывного вейвлет-преобразования (CWT) с использованием вейвлета Морле.

Итоговый набор данных представляет собой изображения, где временная информация сигнала ЭЭГ (ось X) и его частотные характеристики (ось Y) закодированы в виде спектрограмм. Эти изображения используются как входные данные для CNN-LSTM модели, где временная ось помогает выявлять динамику, а частотная — различия между классами Healthy и Seizure.

Для каждого отфильтрованного сигнала применялось CWT с помощью функции `pywt.cwt`. Этот процесс преобразует временной ряд в двумерную матрицу коэффициентов, где:

- ось X соответствует времени;
- ось Y соответствует масштабу (обратно-пропорциональному частоте);

Введение

В данной работе производится классификация временного ряда ЭЭГ для определения эпилепсии. На основе изображений, представляющих вейвлет-преобразование ЭЭГ-сигнала, формируется датасет. С помощью сверточной нейронной сети из данных изображений выделяются полезные признаки, которые затем используются для анализа временного ряда с помощью LSTM-сети.

Введение

В данной работе производится классификация временного ряда ЭЭГ для определения эпилепсии. На основе изображений, представляющих вейвлет-преобразование ЭЭГ-сигнала, формируется датасет. С помощью сверточной нейронной сети из данных изображений выделяются полезные признаки, которые затем используются для анализа временного ряда с помощью LSTM-сети.

В данной работе производится классификация временного ряда ЭЭГ для определения эпилепсии. На основе изображений, представляющих вейвлет-преобразование ЭЭГ-сигнала, формируется датасет. С помощью сверточной нейронной сети из данных изображений выделяются полезные признаки, которые затем используются для анализа временного ряда с помощью LSTM-сети.

В данной работе производится классификация временного ряда ЭЭГ для определения эпилепсии. На основе изображений, представляющих вейвлет-преобразование ЭЭГ-сигнала, формируется датасет. С помощью сверточной нейронной сети из данных изображений выделяются полезные признаки, которые затем используются для анализа временного ряда с помощью LSTM-сети.

- X ось соответствует времени;
- Y ось соответствует масштабу (обратно-пропорциональному частоте);
- значение表示小波系数的幅度。

В данной работе производится классификация временного ряда ЭЭГ для определения эпилепсии. На основе изображений, представляющих вейвлет-преобразование ЭЭГ-сигнала, формируется датасет. С помощью сверточной нейронной сети из данных изображений выделяются полезные признаки, которые затем используются для анализа временного ряда с помощью LSTM-сети.

- значения представляют амплитуду вейвлет-коэффициентов.

На рисунке 1 показан одиночный пример спектрограммы, полученной в результате CWT.




Рис. 1: Пример спектрограммы, полученной с помощью CWT.

1. Вейвлет-преобразование

Вейвлет-преобразование (Wavelet Transform) представляет собой метод анализа сигналов, обеспечивающий совместное рассмотрение их характеристик во времени и частоте. В отличие от преобразования Фурье, которое фокусируется исключительно на частотной области, вейвлет-преобразование использует локализованные базисные функции — вейвлеты, что делает его эффективным для анализа нестационарных сигналов, таких как электроэнцефалограммы (ЭЭГ) из датасета CHB-MIT Scalp EEG Database.

Непрерывное вейвлет-преобразование (CWT) определяется следующим образом:

$$W(a, b) = \frac{1}{\sqrt{|a|}} \int_{-\infty}^{\infty} x(t) \psi^* \left(\frac{t-b}{a} \right) dt, \quad (1)$$

где:

- $x(t)$ — анализируемый сигнал,
- $\psi(t)$ — базисная вейвлет-функция,
- $\psi^*(t)$ — комплексно-сопряженная вейвлет-функция,
- a — параметр масштаба (обратнопропорционален частоте),




Рис. 1: Через CWT获得的谱图示例。

1. 小波变换

小波变换 (Wavelet Transform) 是一种信号分析方法，可同时考虑信号的时间和频率特性。与仅关注频率域的傅里叶变换不同，小波变换使用局部化的基函数——小波，使其特别适合分析非平稳信号，如 CHB-MIT Scalp EEG Database 中的脑电图 (EEG)。

连续小波变换 (CWT) 定义如下：

$$W(a, b) = \frac{1}{\sqrt{|a|}} \int_{-\infty}^{\infty} x(t) \psi^* \left(\frac{t-b}{a} \right) dt, \quad (1)$$

其中：

- $x(t)$ — 被分析的信号，
- $\psi(t)$ — 基小波函数，
- $\psi^*(t)$ — 共轭小波函数，
- a — 尺度参数（与频率成反比），
- b — 时间偏移参数，
- $\frac{1}{\sqrt{|a|}}$ — 用于保持能量的归一化系数。

尺度 a 确定小波的宽度，偏移 b 允许在不同时间点分析信号。频率与尺度的关系为 $f = \frac{f_c}{a}$ ，其中 f_c 为小波的中心频率， f_s 为信号的采样率。

本研究中使用的是 Morlet 小波，其定义为：

$$\psi(t) = e^{-t^2/2} \cdot e^{i\omega_0 t}, \quad (2)$$

其中 ω_0 为振荡频率（通常为 $\omega_0 = 6$ 以获得最佳定位）。该小波结合了高斯包络和振荡，提供了时间和频率分辨率的平衡。

- b — параметр сдвига во времени,
- $\frac{1}{\sqrt{|a|}}$ — нормировочный коэффициент для сохранения энергии.

Масштаб a определяет ширину вейвлета, а сдвиг b позволяет анализировать сигнал в различных временных точках. Связь частоты с масштабом выражается как $f = \frac{f_c}{a} \cdot f_s$, где f_c — центральная частота вейвлета, а f_s — частота дискретизации сигнала.

В данной работе использовался вейвлет Морле, описываемый уравнением:

$$\psi(t) = e^{-t^2/2} \cdot e^{i\omega_0 t}, \quad (2)$$

где ω_0 — частота осцилляции (обычно $\omega_0 = 6$ для оптимальной локализации). Этот вейвлет сочетает гауссову оболочку с осцилляцией, обеспечивая баланс между временной и частотной разрешающей способностью.

2. Обучение нейронной сети

В качестве пациентов для обучения нейронной сети были выбраны пациенты 3, 5 и 6. В работе использовались две архитектуры сети: CNN+LSTM и CNN. Первая архитектура соответствовала модели, представленной в эталонном решении, а вторая была составлена самостоятельно. Также в эталонном решении использовалась функция активации sigmoid, а во втором решении — softmax. В остальном модели схожи.

На рисунках 2 и 3 показаны результаты обучения. Видно, что они получились неудовлетворительными, что говорит либо о несовершенстве модели, либо о несовершенстве датасета. Из рисунков видно, что понять, здоров пациент или у него эпилепсия, не представляется возможным. Поэтому неточность в обучении, по моему личному мнению, связана с неточностью данных, неправильным подходом к их обработке или в принципе неправильной методологией решения данной задачи.

2. Нейронная сеть

Как объект для обучения нейронной сети, были выбраны пациенты 3, 5 и 6. В работе использовались две архитектуры: CNN+LSTM и CNN. Первая архитектура соответствует модели из эталонного решения, вторая — разработана самостоятельно. В эталонном решении использовалась функция активации sigmoid, а во втором решении — softmax. Кроме того, обе модели схожи.

Результаты обучения показаны на рисунках 2 и 3. Результаты не вызывают удовлетворения, что может свидетельствовать о проблемах с моделью или данными. Из графиков видно, что невозможно однозначно определить, здоров ли пациент или страдает эпилепсией. Следовательно, неточность обучения, на мой личный взгляд, обусловлена неточностью данных, неверным подходом к их обработке или, возможно, самой методологией решения задачи.

Classification Report:				
	precision	recall	f1-score	support
0	0.50	1.00	0.67	13
1	1.00	0.19	0.32	16
accuracy			0.55	29
macro avg	0.75	0.59	0.49	29
weighted avg	0.78	0.55	0.47	29

Accuracy: 0.5517241379310345

Рис. 2: CNN-LSTM модели результаты обучения.

Classification Report:				
	precision	recall	f1-score	support
0	0.45	1.00	0.62	13
1	0.00	0.00	0.00	16
accuracy			0.45	29
macro avg	0.22	0.50	0.31	29
weighted avg	0.20	0.45	0.28	29

Accuracy: 0.4482758620689655

Рис. 3: CNN модели результаты обучения.

Рисунок 4 показывает примеры данных для обучения. Из них можно увидеть, что невозможно однозначно...




Рис. 4: Примеры данных для обучения.

3. Заключение

В работе использовалась модель на основе преобразования вейвлет-сигналов EEG в изображения и сверточной нейронной сети. Для EEG-последовательностей проводился классификационный анализ эпилепсии. Результаты не идеальны. На текущем этапе можно сказать, что применение данного метода не привнесло положительных результатов.

Classification Report:				
	precision	recall	f1-score	support
0	0.50	1.00	0.67	13
1	1.00	0.19	0.32	16
accuracy			0.55	29
macro avg	0.75	0.59	0.49	29
weighted avg	0.78	0.55	0.47	29

Accuracy: 0.5517241379310345

Рис. 2: Результаты обучения CNN-LSTM модели.

Classification Report:				
	precision	recall	f1-score	support
0	0.45	1.00	0.62	13
1	0.00	0.00	0.00	16
accuracy			0.45	29
macro avg	0.22	0.50	0.31	29
weighted avg	0.20	0.45	0.28	29

Accuracy: 0.4482758620689655

Рис. 3: Результаты обучения CNN модели.

На рис. 4 показан пример тренировочных данных. На них видно, что однозначно нельзя определить




Рис. 4: Пример тренировочных данных

3. Подведение итогов

В данной работе была произведена классификация временного ряда ЭЭГ для определения эпилепсии на основе изображений, представляющих вейвлет-преобразование ЭЭГ-сигнала с помощью сверточной нейронной сети. Результаты оказались неудачными. На данном этапе работы можно сказать, что применение данной методологии не дает положительных результатов.