

Отчёт 7

ИУ1И-41М Цен Лэшань

28 апреля 2025г.

1 Цель работы

Исследование возможности распознавания моторных образов (сжимаем левый или правый кулак) с использованием методов глубокого обучения. Обработать набор данных ЭЭГ (электроэнцефалографии) для решения задачи бинарной классификации.

1 目标

使用深度学习方法识别运动图像（握紧左拳或右拳）的可能性的研究。处理 EEG（脑电图）数据集，以解决二分类问题。

2 Основные задачи

- Преобразование временных ЭЭГ-сигналов в спектрограммы (STFT) / скалограммы (CWT).
- Обучения CNN-2D и гибридной модели CNN-2D+STM для классификации.
- Оценка точности моделей и интерпретация результатов.

2 主要任务

- 时间脑电信号转换成频谱图(STFT)或标量图(CWT)。
- CNN-2D 和 CNN-2D + LSTM 混合模型进行分类的训练。
- 模型精度的评估和结果的解释。

3 Метод

Датасет

Тренировочные данные: 400 образцов (MI-EEG-B9T.csv).
Тестовые данные: 320 образцов (MI-EEG-B9E.csv).

3 方法

数据集

训练数据：400 个样本 (MI-EEG-b9t.csv)。
测试数据：320 个样本 (MI-EEG-b9e.csv)。

Целевые метки: 2 класса (1 — левая рука, 2 — правая рука). 目标标签: 2 类 (1-左手, 2-右手).


Препроцессинг сигналов

STFT (кратковременное преобразование Фурье): 信号预处理

Фурье):

STFT (短时傅立叶变换): 转换耗时: 1.39s

Время преобразования STFT: 1,39 секунды




(pic.1.1 STFT+CNN-2D + LSTM)

CWT (вейвлет-преобразование):

CWT (小波变换): 转换耗时: 39.18s

Время преобразования CWT : 39,18 секунды



(pic.1.2 CWT+CNN-2d)

CWT (вейвлет-преобразование):

Время преобразования CWT : 39,18 секунды

CWT (小波变换): 转换耗时: 39.18s

Архитектуры моделей

CNN-2D:

2 сверточных слоя (4 фильтра, ядро 3×3). Макс-пулинг (2×2), полносвязный слой (32 нейрона), Dropout (0.5).

CNN-2D + LSTM:

TimeDistributed-слои для обработки временных последовательностей. LSTM (4 нейрона), полносвязный слой (32 нейрона).

模型架构

CNN-2D: 2 卷积层 (4 个滤波器, 3×3 核)。最大池 (2×2), 全连接层 (32 个神经元), 辍学 (0.5)。

CNN-2D+LSTM: TimeDistributed-用于处理时序的图层。LSTM (4 个神经元), 全连接层 (32 个神经元)。

Обучите и оцените модель

训练并评估模型 (5 次迭代取平均)

(в среднем 5 итераций)

损失、准确率、kappa 系数
训练时间表分析、混淆矩阵

STFT+CNN-2d + LSTM:

Resultados:


loss: [0.465399831533432, 0.4688226580619812, 0.45474928617477417, 0.4967478811740875, 0.5323611497879028]


accuracy: [0.784375011920929, 0.7906249761581421, 0.784375011920929, 0.7593749761581421, 0.765625]

kappa: [np.float64(0.5625)]

time_elapsed: 93.18581914901733


Анализ графиков обучения





(pic.2.1 STFT+CNN-2D + LSTM)

Матрица ошибок



(pic.3.1 STFT+CNN-2D + LSTM)

Структура модели

Layer (type)	Output Shape	Param #
conv2d_8 (Conv2D)	(None, 67, 500, 4)	40
max_pooling2d_8 (MaxPooling2D)	(None, 33, 250, 4)	0
conv2d_9 (Conv2D)	(None, 33, 250, 4)	148
max_pooling2d_9 (MaxPooling2D)	(None, 16, 125, 4)	0
flatten_4 (Flatten)	(None, 8000)	0
dense_8 (Dense)	(None, 32)	256,032
dropout_4 (Dropout)	(None, 32)	0
dense_9 (Dense)	(None, 2)	66

Mean Accuracy: 0.7769

std: (+/- 0.0121)

Mean Kappa: 0.5625

std: (+/- 0.0000)
Max Accuracy: 0.7906
Max Kappa: 0.5625
time_elapsed: 93

CWT+CNN-2d:

Resultados:

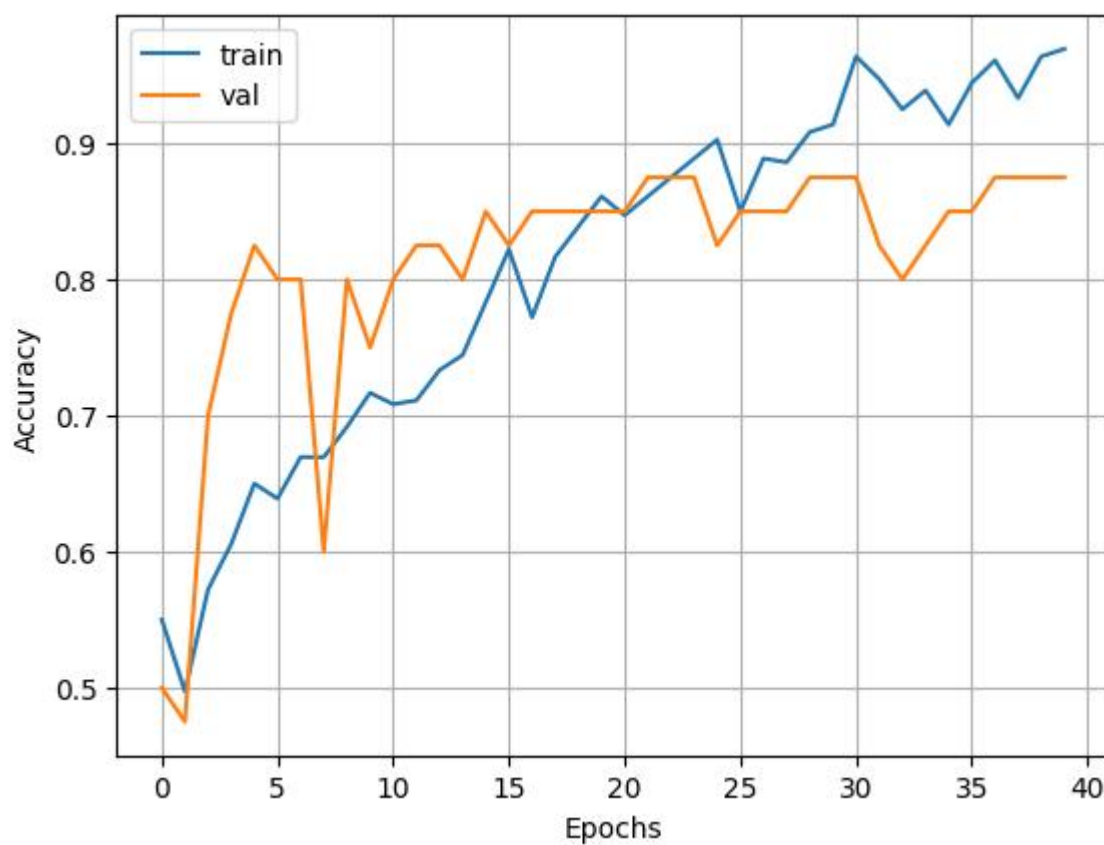
loss: [0.5164342522621155, 0.6660228967666626, 0.49912315607070923, 0.4461180567741394, 0.5585890412330627]


accuracy: [0.796875, 0.7875000238418579, 0.793749988079071, 0.7718750238418579, 0.7875000238418579]

kappa: [np.float64(0.575)]

time_elapsed: 70.45216512680054

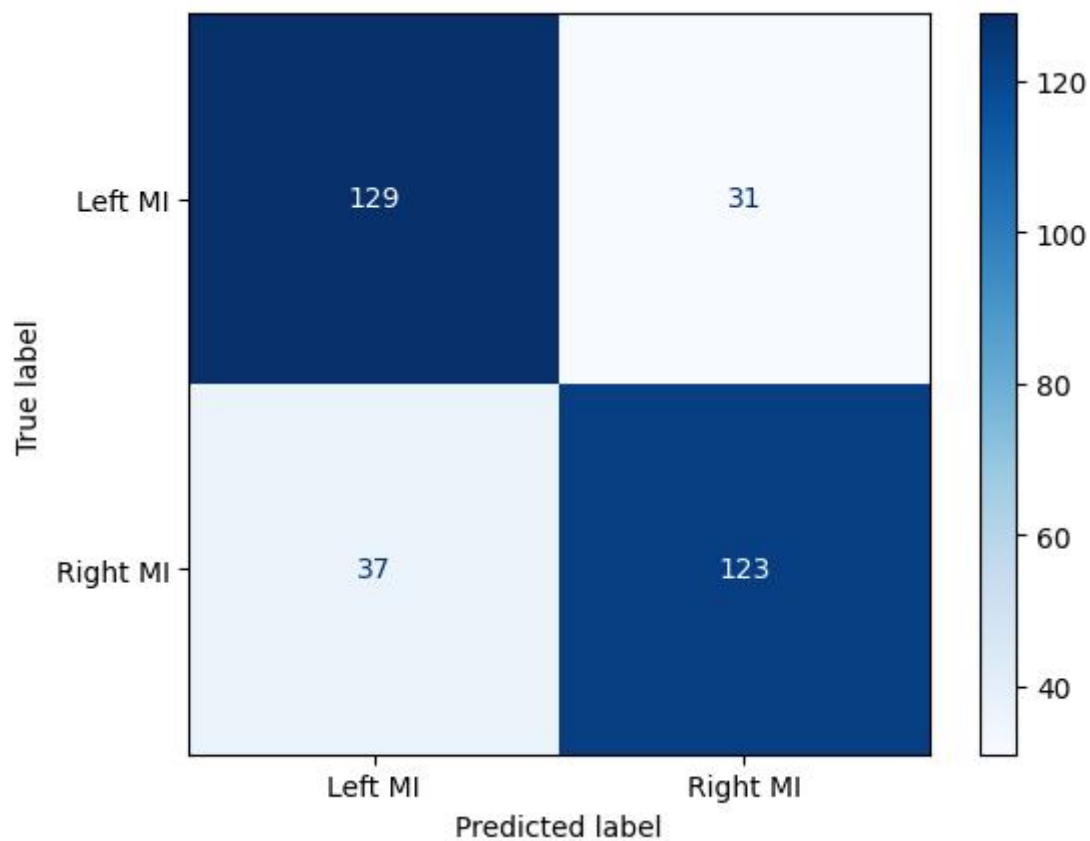
Анализ графиков обучения





(pic.2.2 CWT+CNN-2d)

Матрица ошибок



(pic.3.2 STFT+CNN-2D + LSTM)

Структура модели

Layer (type)	Output Shape	Param #
time_distributed_20 (TimeDistributed)	(None, 1, 135, 31, 4)	40
time_distributed_21 (TimeDistributed)	(None, 1, 67, 15, 4)	0
time_distributed_22 (TimeDistributed)	(None, 1, 67, 15, 4)	148
time_distributed_23 (TimeDistributed)	(None, 1, 33, 7, 4)	0
time_distributed_24 (TimeDistributed)	(None, 1, 924)	0
lstm_4 (LSTM)	(None, 4)	14,864
dense_8 (Dense)	(None, 32)	160
dense_9 (Dense)	(None, 2)	66

Mean Accuracy: 0.7875
std: (+/- 0.0086)
Mean Kappa: 0.5750
std: (+/- 0.0000)
Max Accuracy: 0.7969
Max Kappa: 0.5750
time_elapsed: 70

4 Выводы

1. Использование методов глубокого обучения эффективно для задач классификации
2. Основные ограничения: небольшой объем данных и возможность оптимизации гиперпараметров.

4 结论

1. 有效地将深度学习方法用于分类任务
2. 主要限制是数据量小和优化超参数的能力。

References

<https://github.com/TAUforPython/BioMedAI/blob/main/NN%20CNN%20LSTM%20EEG%20DF%20MI%20Class.ipynb>