

1. Цель

- Подготовка данных: извлеките данные ЭЭГ, содержащие эпилептические приступы, из базы данных CHB-MIT и создайте не менее 50 изображений эпилептических приступов и 50 изображений без приступов.
- Генерация изображения: извлеченный сигнал ЭЭГ обрезается по времени, и изображение генерируется с помощью вейвлет-преобразования.
- Обучение модели: создание и обучение модели CNN для различения изображений ЭЭГ, содержащих эпилептические приступы, от изображений без них.
- Оценка модели: сохраните обученную модель и оцените ее эффективность на тестовом наборе.

2. Методы

- 1) Источник данных и обработка
- Источник данных: База данных эпилепсии PhysioNet CHB-MIT
 - Частота дискретизации: 256 Гц
 - Извлечь временной период (начало, конец) эпилептического приступа путем анализа файла *-summary.txt
- 2) Фильтрация частотного диапазона ЭЭГ
- Используйте полосовой фильтр Баттерворта для извлечения пяти типов мозговых волн:

1. 实验目标

- 数据准备：从 CHB-MIT 数据库中提取含有癫痫发作的 EEG 数据，生成至少 50 张癫痫发作图像和 50 张非发作图像。
- 图像生成：对提取的 EEG 信号进行时间裁剪，并通过小波变换生成图像。
- 模型训练：构建并训练 CNN 模型，以区分含有癫痫发作和不含发作的 EEG 图像。
- 模型评估：保存训练好的模型，并评估其在测试集上的性能。

2. 方法

- 1) 数据来源与处理
- 数据来源：PhysioNet CHB-MIT 癫痫数据库
 - 采样率：256Hz
 - 通过解析*-summary.txt 文件提取癫痫发作的时间段（start, end）
- 2) EEG 频段滤波
- 使用巴特沃斯带通滤波器提取五类脑电波：

Группа/波段	Диапазон частот (Гц)/频率范围 (Hz)	Физиологическое значение/生理含义
Delta	1–4	Глубокий сон/深度睡眠
Theta	4–8	Расслабление, легкий сон/放松、浅睡
Alpha	8–14	Состояние покоя/静息状态
Beta	14–30	Активность, бдительность/活动、警觉
Gamma	30–50	Познание высшего порядка/高阶认知

Формула нормализации фильтра:

滤波器归一化公式:

$$\omega_{low} = \frac{f_{low}}{f_s/2}, \omega_{high} = \frac{f_{high}}{f_s/2}$$

3) Непрерывное вейвлет-преобразование (CWT)

3) 连续小波变换 (CWT)

使用 Morlet 小波进行时间-频率表示:

Частотно-временное представление с использованием вейвлета Морле:

$$W_x(a, b) = \frac{1}{\sqrt{a}} \int_{-\infty}^{\infty} x(t) \varphi^*\left(\frac{t-b}{a}\right) dt$$

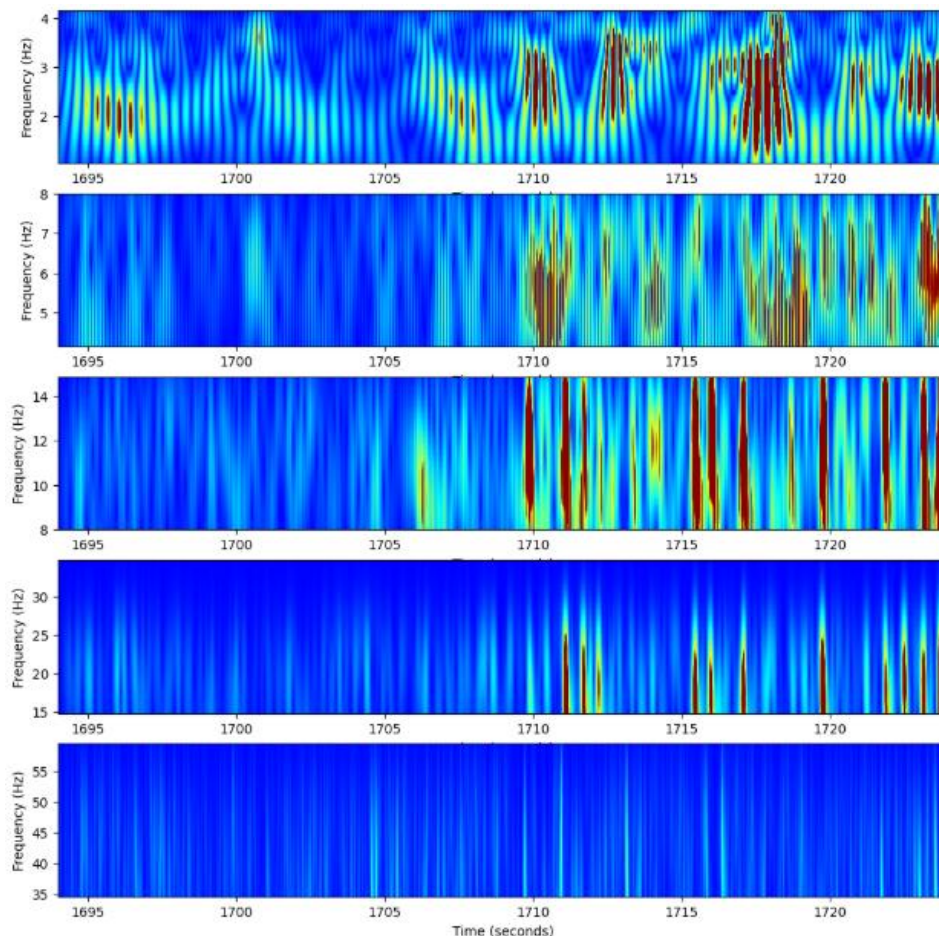
Соотношение между масштабом и частотой:

尺度与频率的关系:

$$f = \frac{f_c}{a * \Delta t}$$

Размер сгенерированного изображения составляет 512x512, а пять подизображений соответствуют пяти частотным диапазонам соответственно.

生成图像大小: 512x512, 五张子图分别对应五个频段。



4) Структура папок изображений классификации
- wavelet_img/Seizure/: 30/60/90 секунд до приступа
wavelet_img/Healthy/: Случайные сегменты без атак
Всего создано: 100 изображений (50 «Приступ» + 50 «Здоровье»)

5) Построение модели CNN-LSTM
a) Структурное резюме:

Conv2D(32) + BN + MaxPool
→ Conv2D(64) + MaxPool
→ Conv2D(128) + MaxPool
→ Flatten → Dense(64) + Reshape
→ LSTM(64) → Dense(32) → Dense(2)

б) Модуль CNN

Свёрточные нейронные сети в основном используются для извлечения пространственных локальных особенностей на изображениях и особенно подходят для распознавания полосовой текстуры на вейвлет-изображениях. Многомасштабные частотно-временные характеристики извлекаются с помощью трех слоев свертки и, наконец, сводятся в векторы с помощью Flatten и вводятся в LSTM.

в) Сплюсчивание → Плотность (64):

- Преобразовать тензор пространственных признаков в одномерный вектор;
- Подключиться к слою Dense для предварительного нелинейного картирования;
- Добавлена регуляризация L2 для управления размером параметра:

$$L_{reg} = \lambda ||W||_2^2$$

4) Классификация изображений

- wavelet_img/Seizure/: 30/60/90 секунд до приступа
- wavelet_img/Healthy/: Случайные сегменты без атак

Всего создано: 100 изображений (50 Seizure + 50 Healthy)

5) CNN-LSTM модель построения
a) Структурное резюме:

б) Модуль CNN

Свёрточные нейронные сети в основном используются для извлечения пространственных локальных особенностей на изображениях и особенно подходят для распознавания полосовой текстуры на вейвлет-изображениях. Многомасштабные частотно-временные характеристики извлекаются с помощью трех слоев свертки и, наконец, сводятся в векторы с помощью Flatten и вводятся в LSTM.

в) Сплюсчивание → Плотность (64):

- Преобразовать тензор пространственных признаков в одномерный вектор;
- Подключиться к слою Dense для предварительного нелинейного картирования;
- Добавлена регуляризация L2 для управления размером параметра:

г) Изменение формы → LSTM(64):

- Поскольку LSTM требует последовательного ввода, измените плотный вывод на (1, 64);
- LSTM-единицы используются для моделирования «временных отношений» изображений (фактически последовательностей встроенных признаков).

д) Reshape → LSTM(64):

- 由于 LSTM 需要序列输入, 将 Dense 输出 reshape 为 (1, 64);
- LSTM 单元用于建模图像的“时间关系” (实际为嵌入特征序列)。

3. Обучение и оценка модели

1) Функция потерь и оптимизация

- Функция потерь: перекрестная энтропия

$$L = - \sum y_i \log(\hat{y}_i)$$

- Оптимизатор: Адам, скорость обучения 0.001
- Вес класса: сбалансировать соотношение эпилепсии и данных о состоянии здоровья
- EarlyStopping: отслеживание точности проверочного набора для предотвращения переобучения

3. 模型训练与评估

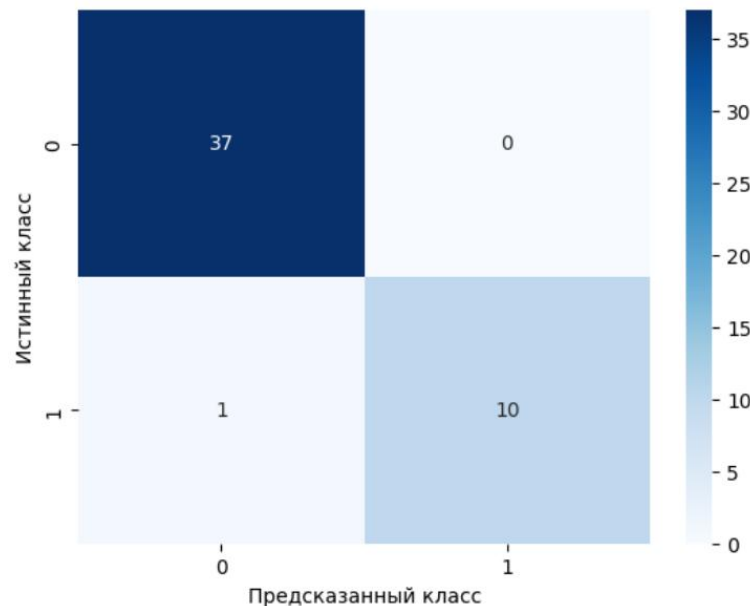
1) 损失函数与优化

- 损失函数: 交叉熵

- 优化器: Adam, 学习率 0.001

- Class weight: 平衡癫痫与健康数据比例

- EarlyStopping: 监控验证集准确率, 防止过拟合

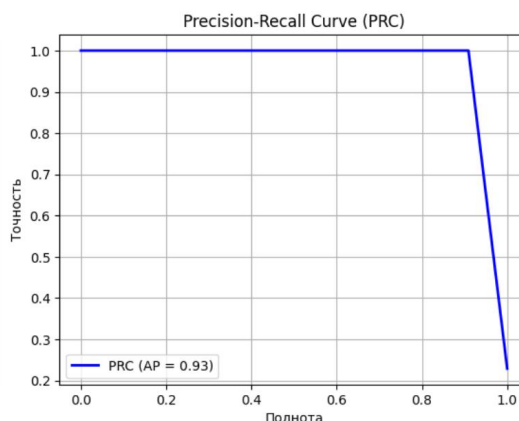
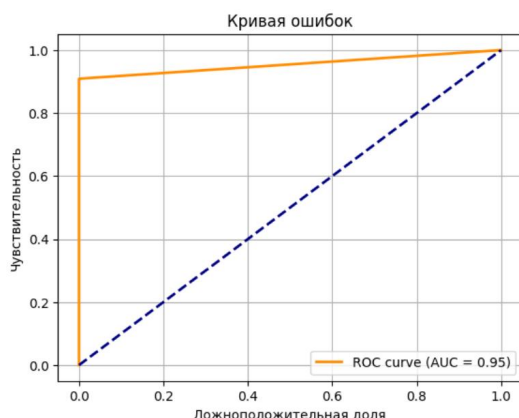


2) Кривые ROC и PRC

Постройте кривую ROC (TPR против FPR) и кривую PRC (точность против полноты), а AUC отразит общую производительность.



2) ROC 与 PRC 曲线

绘制 ROC 曲线 (TPR vs FPR) 与 PRC 曲线 (Precision vs Recall), AUC 表示综合性能。



3) Визуализация обучения

- На левом рисунке показана тенденция изменения функции потерь в зависимости от количества эпох.
- На правом рисунке показан процесс улучшения точности классификации модели.
- Если обе кривые имеют тенденцию к стабильности, а проверочная кривая не имеет явных колебаний, это означает, что модель хорошо обучена.



3) 学习可视化

- 左图表示损失函数随迭代轮数（Epochs）变化的趋势。
- 右图表示模型分类准确率的提升过程。
- 若两条曲线趋于平稳且验证曲线无明显抖动，说明模型训练良好。

4. Заключение

1) В этом проекте использовалось непрерывное вейвлет-преобразование (CWT) для преобразования временных рядов данных ЭЭГ в двумерные изображения, что позволило реализовать визуальный спектральный анализ нелинейных и нестационарных сигналов ЭЭГ и эффективно улучшить разделимость признаков эпилепсии.

4. 实验结论

1) 本项目采用了连续小波变换（CWT）将时序 EEG 数据转化为二维图像，实现了非线性非平稳脑电信号的可视化频谱分析，有效提升了癫痫特征的可分性。

2) Сверточная нейронная сеть отвечает за извлечение пространственных спектральных паттернов изображения, а слой LSTM используется для моделирования глубокой структуры внедрения вейвлет-изображения ЭЭГ. Комбинированная структура обладает высокой способностью моделировать совместные частотно-временные характеристики в данных ЭЭГ.

3) Действительность модели:

- Образцы изображений построены на основе данных трех пациентов, chb06–chb08;
- Использовать полосовые фильтры для выделения пяти частотных диапазонов (δ – γ);
- Каждое изображение содержит субизображения CWT пяти частотных диапазонов, формы изображений однородны, а данные полностью нормализованы;
- Модель достигла высокой точности в проверочном наборе, показав сильную обобщающую способность для задач обнаружения эпилептических приступов.

2)卷积神经网络负责提取图像空间频谱模式, LSTM 层用于建模 EEG 小波图像的深层嵌入结构, 其组合结构对脑电数据中的时频联合特征建模能力强。

3) 模型有效性:

- 图像样本从 chb06–chb08 共三位病人数据中构建;
- 使用带通滤波器隔离五类频段 (δ – γ);
- 每张图像包含五个频带的 CWT 子图, 图像形状统一, 数据归一化充分;
- 模型在验证集中实现高准确率, 显示出对癫痫发作检测任务的强泛化能力。

5. Ссылки на литературу

- [1] Goldberger AL, et al. "PhysioBank, PhysioToolkit, and PhysioNet: Components of a New Research Resource for Complex Physiologic Signals." *Circulation* 101.23 (2000): e215–e220. doi:10.1161/01.CIR.101.23.e215
- [2] Mallat, S. "A Wavelet Tour of Signal Processing: The Sparse Way." Academic Press, 3rd edition, 2009.
- [3] Hochreiter, S., & Schmidhuber, J. "Long short-term memory." *Neural computation*, 1997.
- [4] LeCun, Y., et al. "Deep learning." *Nature* 521.7553 (2015): 436–444.
- [5] Subasi, A. "EEG signal classification using wavelet feature extraction and a mixture of expert model." *Expert Systems with Applications* 32.4 (2007): 1084–1093.