

# Отчёт

## 报告

Джин Хэ

金赫

12 апреля 2025г.

2025 年 4 月 12 日

### 1 Цель работы

Обработать набор данных ЭЭГ (электроэнцефалографии) для решения задачи бинарной классификации.

Конкретно: на основе данных ЭЭГ обнаружить особенности моторного воображения — различить, выполняет ли испытуемый мысленное представление действия "сжатие кулака левой руки" или "сжатие кулака правой руки".

### 2 Метод

(1) Преобразовать временные сигналы в изображения с помощью вейвлет-преобразования;

(2) Обучить нейронную сеть для распознавания когнитивных особенностей мозга;

(3) Конкретная цель классификации: обнаружение особенностей моторного воображения — различить, представляет ли испытуемый действие «сжатие кулака левой руки» или «сжатие кулака правой руки».

### 3 Обсуждение

### 1 目标

处理 EEG (脑电图) 数据集, 以解决二分类问题。

具体来讲, 基于 EEG (脑电图) 数据检测运动想象特征——区分受试者是在想象 "握紧左手拳头" 还是 "握紧右手拳头" 的动作。

### 2 方法

(1) 通过小波变换将时域信号转换为图像;

(2) 训练神经网络识别大脑认知特征;

(3) 具体分类目标: 检测运动想象特征——区分受试者是在想象 "握紧左手拳头" 还是 "握紧右手拳头" 的动作

### 3 操作

В результате проверки данных установлено, что размерность обучающего набора данных (B9T) составляет (400, 3000), то есть он содержит 400 образцов с временными сигналами длиной 3000. Тестовый набор данных (B9E) имеет размерность (320, 3000), то есть включает 320 образцов с аналогичной длиной временных сигналов (3000). Таким образом, данные в наборе характеризуются высокой размерностью, и традиционные прямые модели (feedforward) непригодны для обучения на таких данных, тогда как сверточные нейронные сети (CNN) решают эту проблему [1].

В задаче классификации ЭЭГ на основе моторного воображения: Входные данные — 4-секундные фрагменты ЭЭГ с трёх каналов C3, Cz, C4; Выходные данные — бинарная классификация: различение моторного воображения действий «левой руки» и «правой руки».

Метки в обучающем и тестовом наборах данных принадлежат к категориям {0} и {1}, что подтверждает задачу бинарной классификации. Здесь: {0} соответствует «левой руке», {1} соответствует «правой руке».

### 3.1 STFT + CNN-2D + LSTM

Частота дискретизации ЭЭГ составляет 250 Гц. Общая высота выходного спектрограммы — 135 пикселей, ширина — 31 временное измерение, количество каналов — 3, длина сигнала одного канала — 1000 временных точек, а число точек перекрытия окна при STFT (кратковременное преобразование Фурье) — 225.

Спектр обрезан по строкам 16–60, что соответствует частотному диапазону 8–30 Гц, охватывающему мю-ритм ЭЭГ (8–12 Гц) и бета-ритм (13–30 Гц).

После обработки STFT: Размерность обучающего набора данных — (400, 135, 31), то есть 400 образцов, 135 частотных

каналов, 31 временных точек. После проверки данных,训练数据 (B9T) 维度为 (400, 3000), 即包含 400 个样本, 时序信号长度为 3000; 测试数据 (B9E) 维度为 (320, 3000), 即包含 320 个样本, 时序信号长度同样为 3000。由此可知, 数据集数据维度较高, 传统的前馈模型不适用于训练此类高维数据, 而 CNN 解决了这一问题[1]。

运动想象 EEG 分类任务中, 输入为 3 通道 C3/Cz/C4 的 4 秒 EEG 片段; 输出为左右手运动想象的二分类。

训练数据集与测试数据集标签包含 {0} 和 {1}, 说明对应的是二分类任务。其中 {0} 代表左手、{1} 代表右手。

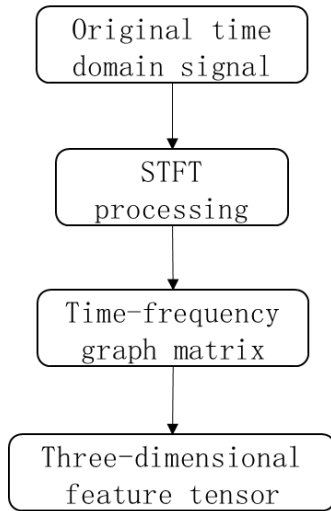
### 3.1 STFT + CNN-2D + LSTM

EEG 采样频率为 250Hz, 输出谱图的总高度为 135 像素, 宽度为 31 个时间维度, 通道数为 3 通道, 单通道信号长度为 1000 个时序点, STFT 窗口重叠点数为 225。

频谱截取了第 16–60 行, 对应的频率范围是 8Hz 至 30Hz; 覆盖了 EEG 的  $\mu$  节律 (8–12Hz) 和  $\beta$  节律 (13–30Hz)。


经过 STFT 处理, 训练数据集维度为 (400, 135, 31), 即包含 400 个样本, 135 个频率通道, 31 个时间帧; 测试数据集维度为

каналов, 31 временной кадр; Размерность тестового набора данных — (320, 135, 31), то есть 320 образцов, 135 частотных каналов, 31 временной кадр. Технологическая схема процесса представлена ниже.




Максимальное значение в наборе данных вычисляется для выполнения нормализации, которая масштабирует диапазон данных в интервал [0, 1) с целью устранения различий в оборудовании.

Результат этого процесса показан на изображении ниже (на примере первой группы данных): Горизонтальная ось представляет временную шкалу, Вертикальная ось соответствует частотной шкале.




Далее выполняется расширение размерности: наборы данных преобразуются в 5D-структуру для совместимости

(320, 135, 31), то есть 320 образцов, 135 частотных каналов, 31 временной кадр. Технологическая схема процесса представлена ниже.



计算数据集中的最大值，进行归一化处理，将数据范围缩放到 [0, 1) 区间，以消除设备差异。

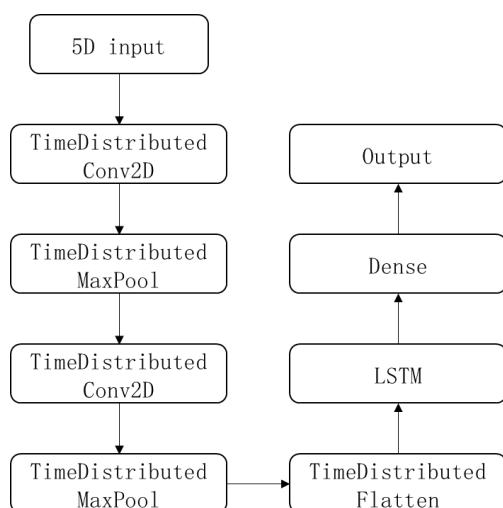
得到如下图所示的结果 (以第一组数据为例): 横轴为时间尺度, 纵轴为频率尺度。



接下来扩展维度，将数据集转化为 5D, 使其适用于 CNN-LSTM 混合模型。即维度分别

с гибридной моделью CNN-LSTM (сверточная нейронная сеть + долгая краткосрочная память). А именно: Размерности становятся (400, 1, 135, 31, 1) для обучающего набора, (320, 1, 135, 31, 1) для тестового набора.

Технологическая схема гибридной модели CNN-LSTM представлена ниже.

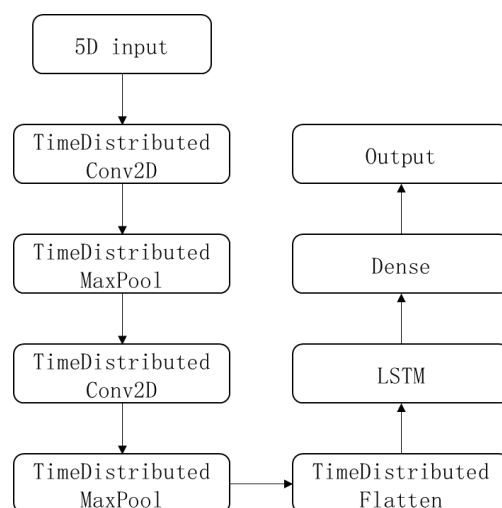


Для проверки стабильности модели и её средней производительности проводится обучение модели с 5 повторными экспериментами. Обучение выполняется в течение 70 эпох с размером пакета 36 образцов, при этом 10% набора данных выделяется в качестве проверочного набора. В данной стратегии оценки независимый тестовый набор гарантирует объективность результатов, а двойные метрики (потери и точность) полно отражают производительность модели.

Результаты обучения показаны на рисунках ниже: Первый график визуализирует изменение точности в процессе обучения для тренировочного и проверочного наборов. Чем выше кривая, тем лучше способность модели к обучению и обобщению. Идеальный сценарий — синхронный рост и сходимость обеих кривых. Второй график отображает динамику потерь (loss) в процессе обучения.





для (400, 1, 135, 31, 1), (320, 1, 135, 31, 1).

CNN-LSTM гибридной модели технологическая схема представлена ниже.



Выполняется 5 повторных экспериментов модели для проверки стабильности и средней производительности. Обучение выполняется в течение 70 эпох с размером пакета 36 образцов, при этом 10% набора данных выделяется в качестве проверочного набора. В данной стратегии оценки независимый тестовый набор гарантирует объективность результатов, а двойные метрики (потери и точность) полно отражают производительность модели.

Результаты обучения показаны на рисунках ниже: Первый график визуализирует изменение точности в процессе обучения для тренировочного и проверочного наборов. Чем выше кривая, тем лучше способность модели к обучению и обобщению. Идеальный сценарий — синхронный рост и сходимость обеих кривых. Второй график отображает динамику потерь (loss) в процессе обучения.



Результаты обучения представлены на рисунках ниже: Первый график показывает изменение точности в процессе обучения для тренировочного и проверочного наборов. Чем выше кривые, тем лучше способность модели к обучению и обобщению. Идеальный случай — синхронный рост и сходимость обеих кривых. Второй график визуализирует динамику потерь (loss).



Рассчитанный коэффициент согласованности Каппа (Карра) равен 0.61, что указывает на достаточную надёжность для клинического вспомогательного принятия решений, но оставляет пространство для улучшений.

Тепловая карта (heatmap) результатов демонстрирует высокую точность классификации.

Тренировочные результаты показаны на рисунке ниже. Первый график визуализирует изменение точности в процессе обучения для тренировочного и проверочного наборов. Чем выше кривые, тем лучше способность модели к обучению и обобщению. Идеальный случай — синхронный рост и сходимость обеих кривых. Второй график визуализирует динамику потерь (loss).

Результаты вычисления коэффициента согласованности Каппа (Карра) равны 0.61, что указывает на достаточную надёжность для клинического вспомогательного принятия решений, но оставляет пространство для улучшений.

Тепловая карта (heatmap) результатов демонстрирует высокую точность классификации.



Model: "sequential\_14"

Layer (type)	Output Shape	Param #
time_distributed_70 (TimeDistributed)	(None, 1, 135, 31, 4)	40
time_distributed_71 (TimeDistributed)	(None, 1, 67, 15, 4)	0
time_distributed_72 (TimeDistributed)	(None, 1, 67, 15, 4)	148
time_distributed_73 (TimeDistributed)	(None, 1, 33, 7, 4)	0
time_distributed_74 (TimeDistributed)	(None, 1, 924)	0
lstm_14 (LSTM)	(None, 4)	14,864
dense_28 (Dense)	(None, 32)	160
dense_29 (Dense)	(None, 2)	66

Total params: 45,836 (179.05 KB)  
Trainable params: 15,278 (59.68 KB)  
Non-trainable params: 0 (0.00 B)  
Optimizer params: 30,558 (119.37 KB)

Mean Accuracy: 0.7944

std: (+/- 0.0189)

Mean Kappa: 0.6188

std: (+/- 0.0000)

Max Accuracy: 0.8156

Max Kappa: 0.6188

time\_elapsed: 391

### 3.2 CWT + CNN-2D

Частота дискретизации ЭЭГ составляет 250 Гц, исходная спектрограмма имеет высоту 135 пикселей, ширину 31 временное измерение, 3 канала, длина сигнала одного канала — 1000 временных точек.

В качестве вейвлета выбран комплексный вейвлет Морле (cmor3-3) с частотным диапазоном 8–30 Гц (шаг 0.5 Гц), охватывающим мю-ритм ЭЭГ (8–12 Гц) и бета-ритм (13–30 Гц).

Model: "sequential\_14"

Layer (type)	Output Shape	Param #
time_distributed_70 (TimeDistributed)	(None, 1, 135, 31, 4)	40
time_distributed_71 (TimeDistributed)	(None, 1, 67, 15, 4)	0
time_distributed_72 (TimeDistributed)	(None, 1, 67, 15, 4)	148
time_distributed_73 (TimeDistributed)	(None, 1, 33, 7, 4)	0
time_distributed_74 (TimeDistributed)	(None, 1, 924)	0
lstm_14 (LSTM)	(None, 4)	14,864
dense_28 (Dense)	(None, 32)	160
dense_29 (Dense)	(None, 2)	66

Total params: 45,836 (179.05 KB)  
Trainable params: 15,278 (59.68 KB)  
Non-trainable params: 0 (0.00 B)  
Optimizer params: 30,558 (119.37 KB)

Mean Accuracy: 0.7944

std: (+/- 0.0189)

Mean Kappa: 0.6188

std: (+/- 0.0000)

Max Accuracy: 0.8156


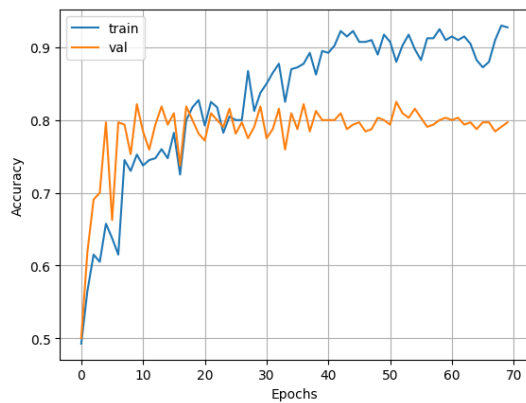

Max Kappa: 0.6188

time\_elapsed: 391

### 3.2 CWT + CNN-2D

EEG采样频率为 250Hz，原始特征图高度为 135 像素，宽度为 31 个时间维度，通道数为 3 通道，单通道信号长度为 1000 个时序点。

小波选择了复 Morlet 小波 (cmor3-3)，频率范围为 8–30Hz (步长 0.5Hz)；覆盖了 EEG 的  $\mu$  节律 (8–12Hz) 和  $\beta$  节律 (13–30Hz)。






Layer (type)	Output Shape	Param #
conv2d_8 (Conv2D)	(None, 67, 500, 4)	40
max_pooling2d_8 (MaxPooling2D)	(None, 33, 250, 4)	0
conv2d_9 (Conv2D)	(None, 33, 250, 4)	148
max_pooling2d_9 (MaxPooling2D)	(None, 16, 125, 4)	0
flatten_4 (Flatten)	(None, 8000)	0
dense_8 (Dense)	(None, 32)	256,032
dropout_4 (Dropout)	(None, 32)	0
dense_9 (Dense)	(None, 2)	66

Mean Accuracy: 0.7831

std: (+/- 0.0145)

Mean Kappa: 0.5938

std: (+/- 0.0000)



Layer (type)	Output Shape	Param #
conv2d_8 (Conv2D)	(None, 67, 500, 4)	40
max_pooling2d_8 (MaxPooling2D)	(None, 33, 250, 4)	0
conv2d_9 (Conv2D)	(None, 33, 250, 4)	148
max_pooling2d_9 (MaxPooling2D)	(None, 16, 125, 4)	0
flatten_4 (Flatten)	(None, 8000)	0
dense_8 (Dense)	(None, 32)	256,032
dropout_4 (Dropout)	(None, 32)	0
dense_9 (Dense)	(None, 2)	66

Mean Accuracy: 0.7831

std: (+/- 0.0145)

Mean Kappa: 0.5938

std: (+/- 0.0000)

Max Accuracy: 0.7969

Max Kappa: 0.5938

time\_elapsed: 133

Max Accuracy: 0.7969

Max Kappa: 0.5938

time\_elapsed: 133

## 4 Ссылки на литературу

### References

- [1] Dose H, Møller J S, Iversen H K, et al. An end-to-end deep learning approach to MI-EEG signal classification for BCIs[J]. Expert Systems with Applications, 2018, 114: 532-542.
- [2] Aghaei A S, Mahanta M S, Plataniotis K N. Separable common spatio-spectral patterns for motor imagery BCI systems[J]. IEEE Transactions on Biomedical Engineering, 2015, 63(1): 15-29.
- [3] Bashivan P, Rish I, Yeasin M, et al. Learning representations from EEG with deep recurrent-convolutional neural networks[J]. arXiv preprint arXiv:1511.06448, 2015.
- [4] Do A H, Wang P T, King C E, et al. Brain-computer interface controlled functional electrical stimulation device for foot drop due to stroke[C]//2012 Annual International Conference of the IEEE Engineering in Medicine and Biology Society. IEEE, 2012: 6414-6417.

## 4 参考文献

### References

- [1] Dose H, Møller J S, Iversen H K, et al. An end-to-end deep learning approach to MI-EEG signal classification for BCIs[J]. Expert Systems with Applications, 2018, 114: 532-542.
- [2] Aghaei A S, Mahanta M S, Plataniotis K N. Separable common spatio-spectral patterns for motor imagery BCI systems[J]. IEEE Transactions on Biomedical Engineering, 2015, 63(1): 15-29.
- [3] Bashivan P, Rish I, Yeasin M, et al. Learning representations from EEG with deep recurrent-convolutional neural networks[J]. arXiv preprint arXiv:1511.06448, 2015.
- [4] Do A H, Wang P T, King C E, et al. Brain-computer interface controlled functional electrical stimulation device for foot drop due to stroke[C]//2012 Annual International Conference of the IEEE Engineering in Medicine and Biology Society. IEEE, 2012: 6414-6417.