

Отчёт 报告

Исса Мохаммад 伊萨·穆罕默德

13 мая 2025 г. 2025 年 5 月 13 日

1 Введение

Электрокардиография (ЭКГ) — это широко используемый метод диагностики сердечных заболеваний. Автоматическая классификация ЭКГ-сигналов может значительно повысить эффективность клинической диагностики. В рамках данной работы мы исследуем характеристики ЭКГ-сигналов и применяем методы глубинного обучения, в частности сети с долгой краткосрочной памятью (LSTM) и механизмом внимания, для классификации сердечных сокращений в соответствии со стандартом, рекомендованным AAMI.

Модель обучается и тестируется на базе MIT-BIH Arrhythmia Database. Этот набор данных включает 48 получасовых фрагментов двухканальных амбулаторных ЭКГ-записей. Аннотации сердечных сокращений приведены к пяти основным категориям согласно стандарту AAMI:

- **N:** Нормальные сокращения
- **S:** Суправентрикулярные экстрасистолы
- **V:** Желудочковые экстрасистолы
- **F:** Слияние нормальных и желудочковых сокращений
- **Q:** Неизвестные или прочие

2 Предобработка данных

- **Выделение сердечных сокращений:** ЭКГ-сигналы сегментируются по сокращениям с использованием аннотаций R-пику из PhysioNet.
- **Длина сигнала:** Каждое сокращение дополняется или обрезается до 300 отсчетов.

1 引言

心电图 (ECG) 是一种广泛用于诊断心脏疾病的技术。自动化的 ECG 信号分类可以提高临床诊断的效率。本研究旨在分析 ECG 信号特征，并应用深度学习方法，特别是带注意力机制的长短期记忆网络 (LSTM)，依据 AAMI 推荐标准对心搏进行分类。

该模型在 MIT-BIH 心律失常数据库上进行训练和测试。该数据库包含 48 段每段 30 分钟的双通道动态 ECG 记录。根据 AAMI 标准，心搏注释被映射为五个主要类别：

- **N:** 正常心搏
- **S:** 室上性异位心搏
- **V:** 室性异位心搏
- **F:** 正常与室性心搏融合
- **Q:** 未知或其他

2 数据预处理

- **心搏提取:** 使用 PhysioNet 中的 R 峰注释将 ECG 信号按心搏分段。
- **信号长度:** 每个心搏被填充或截断为 300 个采样点。

- **Преобразование меток:** Символы сокращений преобразуются в классы AAMI.
- **Нормализация:** Все сегменты нормализуются с использованием z-преобразования.

Датасет является сильно несбалансированным: класс “N” составляет более 80% всех сокращений.

Примечание: Из-за ограниченных ресурсов моего компьютера я использовал только записи с 100 по 180.

3 Архитектура модели

Нейронная сеть включает в себя следующие компоненты:

- LSTM-слой с 64 единицами
- Слой мягкого внимания (Dense + Multiply)
- Второй LSTM-слой с 32 единицами
- Выходной полносвязный слой с softmax-активацией на 5 классов

Общее количество обучаемых параметров: 33,637
 Функция потерь: категориальная кросс-энтропия
 Оптимизатор: Adam

Layer (type)	Output Shape	Param #	Connected to
input_layer (InputLayer)	(None, 300, 1)	0	-
lstm (LSTM)	(None, 300, 64)	10,496	input_layer[][]
dense (Dense)	(None, 300, 32)	9,728	lstm[][]
multiply (Multiply)	(None, 300, 32)	0	lstm[][], dense[][]
lstm_1 (LSTM)	(None, 300, 32)	10,496	multiply[][]
dense_1 (Dense)	(None, 5)	160	lstm_1[][]

Total params: 31,637 (131.39 KB)
 Trainable params: 31,637 (131.39 KB)
 Non-trainable params: 0 (0.00 KB)

Figure 1: Резюме модели

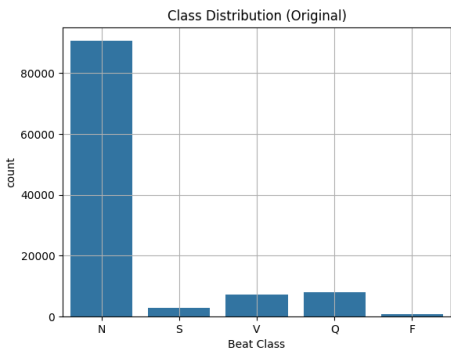


Figure 2: Распределение классов

- **Тегирование:** Серии сокращений с метками AAMI преобразуются в классы AAMI.
- **Тегирование:** Серии сокращений с метками AAMI преобразуются в классы AAMI.

80

备注: 由于我的计算机资源有限,我仅使用了第 100 到第 180 号的记录。

3 模型结构

神经网络由以下部分组成:

- 一个包含 64 个单元的 LSTM 层
- 一个软注意力层 (Dense + Multiply)
- 一个包含 32 个单元的第二 LSTM 层
- 一个具有 5 个节点的 Dense softmax 输出层

总可训练参数: 33,637
 损失函数: 分类交叉熵 (Categorical Crossentropy)
 优化器: Adam

Layer (type)	Output Shape	Param #	Connected to
input_layer (InputLayer)	(None, 300, 1)	0	-
lstm (LSTM)	(None, 300, 64)	10,496	input_layer[][]
dense (Dense)	(None, 300, 32)	9,728	lstm[][]
multiply (Multiply)	(None, 300, 32)	0	lstm[][], dense[][]
lstm_1 (LSTM)	(None, 300, 32)	10,496	multiply[][]
dense_1 (Dense)	(None, 5)	160	lstm_1[][]

Total params: 31,637 (131.39 KB)
 Trainable params: 31,637 (131.39 KB)
 Non-trainable params: 0 (0.00 KB)

Figure 1: 模型摘要




Figure 2: 班级分布

4 Результаты обучения

Модель обучалась в течение 10 эпох на 80% выборки. Во время обучения использовалось 20% данных для валидации. Были применены веса классов для балансировки тренировочного процесса.

Несмотря на балансировку, точность модели остаётся нестабильной и низкой из-за несбалансированности классов и недообучения модели.




Figure 3: Обучение

4 训练结果

该模型使用 80% 的数据进行了 10 轮训练。在训练过程中使用了 20% 的数据作为验证集。为了解决类别不平衡问题，训练中应用了类别权重。

尽管进行了类别平衡处理，但由于类别严重不平衡和模型欠拟合，准确率仍然不稳定且偏低。




Figure 3: 训练

5 Оценка качества модели

Матрица ошибок:

Модель путает класс N с классами Q и S. Миноритарные классы, такие как F и V, предсказываются плохо.




Figure 4: Матрица ошибок

5 评估结果

混淆矩阵:

模型将 N 类与 Q 类和 S 类混淆。少数类（如 F 类和 V 类）的预测效果较差。




Figure 4: 误差矩阵




Figure 5: Точность и потери




Figure 5: 准确率和损失

Отчёт по классификации:

分类报告:

- 准确率 (Accuracy): 12%

- Точность (Accuracy): 12%
- Macro F1-мера: 0.10 → плохая обобщающая способность по всем классам
- Взвешенная F1-мера: 0.08 → отражает влияние несбалансированных данных

	precision	recall	f1-score	support
F	0.00	0.00	0.00	5
N	0.93	0.02	0.05	7965
Q	0.17	0.68	0.27	1217
S	0.01	0.82	0.02	38
V	0.11	0.33	0.16	300
accuracy			0.12	9525
macro avg	0.24	0.37	0.10	9525
weighted avg	0.80	0.12	0.08	9525

Figure 6: Отчёт по классификации

Визуализация t-SNE:

Латентные признаки, извлечённые из предпоследнего LSTM-слоя, не показывают чёткой кластеризации по классам, что указывает на слабую разделимость признаков.

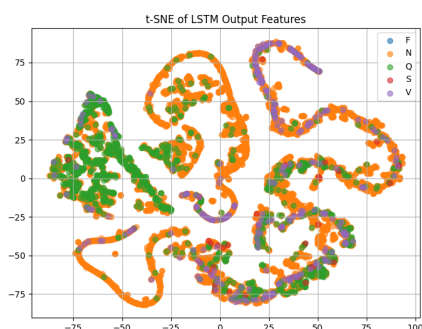


Figure 7: Визуализация t-SNE

6 Заключение

Текущая реализация LSTM с механизмом мягкого внимания демонстрирует ограничения при решении задачи классификации ЭКГ-сигналов с сильным дисбалансом классов. Хотя внимание теоретически должно улучшать результаты за счёт акцента на значимых временных отрезках, доминирование класса "N" приводит к плохому обучению модели на редких классах.

Рекомендации по улучшению:

- Применить увеличение данных или oversampling

- Macro F1分数: 0.10 → 各类别的泛化能力较差
- 加权 F1 分数: 0.08 → 反映了类别不平衡带来的偏差

	precision	recall	f1-score	support
F	0.00	0.00	0.00	5
N	0.93	0.02	0.05	7965
Q	0.17	0.68	0.27	1217
S	0.01	0.82	0.02	38
V	0.11	0.33	0.16	300
accuracy			0.12	9525
macro avg	0.24	0.37	0.10	9525
weighted avg	0.80	0.12	0.08	9525

Figure 6: 分类报告

t-SNE 可视化:

从倒数第二个 LSTM 层提取的潜在特征未表现出明显的类内聚集性, 说明模型难以有效区分不同类别。




Figure 7: t-SNE 可视化

6 结论

目前实现的带软注意力机制的 LSTM 在处理高度不平衡的 ECG 分类任务中表现出一定的局限性。虽然注意力机制在理论上能够通过强调关键时间步提升性能, 但由于 "N" 类的主导地位, 模型在稀有类别上的学习效果较差。

改进建议:

- 对少数类使用数据增强或过采样
- 在 LSTM 层中引入 dropout 和正则化
- 应用更高级的注意力机制 (如 Bahdanau 注意力)

для редких классов

- Ввести dropout и регуляризацию в LSTM-слои
- Использовать более сложные механизмы внимания (например, Bahdanau attention)
- Увеличить число эпох до 30+ с применением ранней остановки (early stopping)
- Предобработать интервалы R-R или использовать многоканальные ЭКГ-входы

Несмотря на неидеальные результаты, предложенный рабочий процесс демонстрирует полноценный пайплайн от предобработки данных до оценки нейросетевой модели и может служить прочной основой для последующих улучшений.

7 Ссылки на литературу

- [1] Набор данных для лабораторных работы и исследований. 2025. URL: <https://github.com/AI-is-out-there/data2lab> (Дата обращения: 16.03.2025)
- [2] TAUforPython. Классификация ЭКГ с помощью LSTM нейросети [Электронный ресурс]. 2023. URL: <https://github.com/TAUforPython/BioMedAI/blob/main/NN%20LSTM%20ECG%20classification.ipynb> (Дата обращения: 14.05.2025)

- 将训练扩展至 30 轮以上，并采用早停策略
- 对 R-R 间期进行预处理，或使用多通道 ECG 输入

尽管当前结果并不理想，但该流程展示了从数据预处理到神经网络评估的完整流程，为未来的改进提供了坚实的基线。

7 参考文献

- [1] AI-is-out-there. 心脏数据集 [EB/OL]. (2025-03-16) [2025-05-06]. <https://github.com/AI-is-out-there/data2lab>
- [2] TAUforPython. LSTM 神经网络用于 ECG 分类 [EB/OL]. (2023) [2025-05-14]. <https://github.com/TAUforPython/BioMedAI/blob/main/NN%20LSTM%20ECG%20classification.ipynb>